

CAPÍTULO X – Estudo Econométrico – Setor do Milho – Aplicação do Modelo de Koyck de Defasagens Ilimitadas

Para o desenvolvimento do modelo econométrico e conclusões apresentadas a seguir, foram utilizadas as variáveis previamente descritas neste documento, reunidas em uma única tabela e transformada em um banco de dados no formato “.csv”. As unidades referentes a quantidades estão em “mil toneladas”, e os valores monetários em Reais. Segue abaixo a tabela, com as variáveis e seus respectivos valores utilizados para a elaboração do modelo:

Anos	Estoque				Câmbio		
	Inicial*	Produção*	Consumo*	Importação*	Exportação*	R\$/USD	Preço (R\$)
2004	9799,56	42125,00	38603,18	299,40	4688,38	R\$ 2,93	R\$ 18,10
2005	8935,90	35007,00	39966,54	596,10	883,27	R\$ 2,43	R\$ 18,41
2006	3688,89	42514,00	40293,03	1011,30	4340,27	R\$ 2,18	R\$ 17,88
2007	2581,79	51370,00	42482,50	1164,30	10862,68	R\$ 1,95	R\$ 23,67
2008	1770,81	58648,00	44853,75	652,00	7368,85	R\$ 1,83	R\$ 25,55
2009	8852,51	51004,00	46499,06	1181,60	7333,92	R\$ 2,00	R\$ 21,02
2010	7204,92	56021,00	48056,36	391,90	10966,12	R\$ 1,76	R\$ 21,51
2011	4592,44	57408,00	50256,26	764,40	9311,90	R\$ 1,67	R\$ 30,32
2012	3195,57	72977,00	51470,77	773,98	22313,70	R\$ 1,95	R\$ 29,81
2013	3164,58	81505,00	52910,96	911,40	26174,05	R\$ 2,16	R\$ 26,99
2014	6496,67	80051,00	54193,12	790,66	20924,80	R\$ 2,35	R\$ 26,87
2015	12221,10	84670,00	55914,97	316,10	30172,34	R\$ 3,33	R\$ 29,05
2016	11122,30	69142,00	54959,70	3338,10	18897,30	R\$ 3,49	R\$ 44,48
2017	7134,00	97842,00	57213,39	953,60	30850,80	R\$ 3,19	R\$ 30,47
2018	17866,22	81360,00	60052,00	901,80	23820,40	R\$ 3,65	R\$ 38,49
2019	15605,12	99985,00	63915,30	800,00	35000,00	R\$ 3,89	R\$ 37,83

* Unidade = mil toneladas

O modelo de Koyck de Defasagens Ilimitadas nos permite elaborar uma análise completa sobre as variáveis que influenciam a produção, bem como estimar os efeitos de variações passadas em qualquer período $t-x$ sobre a produção de hoje no período $t0$; e também estimar os efeitos de Longo Prazo dessas mesmas variações passadas, ou seja, sua influencia

por completo na produção atual e futura. A equação do modelo desenvolvido se dá da seguinte forma:

$$Prod = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \lambda_{prod.t-1} + \mu$$

Onde:

β_1	β_2	β_3	β_4	β_5	β_6
Preço	Câmbio	Consumo Interno	Estoque Inicial	Exportações	Importações

Trabalhamos com o software estatístico RStudio para fazer a regressão e estimativas.

Com o banco de dados carregado, o mesmo foi transformado em uma série temporal de frequência 1, uma vez que estamos trabalhando com observações anuais.

```
> milho.ts
Time Series:
Start = 2004
End = 2019
Frequency = 1
```

	Estoque.Inicial	Prod	Cons	Imp	Exp	Cambio	Preco
2004	9799.565	42125	38603.18	299.400	4688.384	2.93	18.10
2005	8935.898	35007	39966.54	596.100	883.273	2.43	18.41
2006	3688.890	42514	40293.03	1011.300	4340.273	2.18	17.88
2007	2581.788	51370	42482.50	1164.300	10862.677	1.95	23.67
2008	1770.807	58648	44853.75	652.000	7368.853	1.83	25.55
2009	8852.509	51004	46499.06	1181.600	7333.924	2.00	21.02
2010	7204.921	56021	48056.36	391.900	10966.118	1.76	21.51
2011	4592.438	57408	50256.26	764.400	9311.900	1.67	30.32
2012	3195.574	72977	51470.77	773.980	22313.700	1.95	29.81
2013	3164.582	81505	52910.96	911.400	26174.050	2.16	26.99
2014	6496.671	80051	54193.12	790.655	20924.800	2.35	26.87
2015	12221.104	84670	55914.97	316.100	30172.337	3.33	29.05
2016	11122.300	69142	54959.70	3338.100	18897.300	3.49	44.48
2017	7134.003	97842	57213.39	953.600	30850.800	3.19	30.47
2018	17866.216	81360	60052.00	901.800	23820.400	3.65	38.49
2019	15605.116	99985	63915.30	800.000	35000.000	3.89	37.83

Utilizamos o pacote chamado “dynlm” para o R, cuja função é lidar com modelos de regressões lineares dinâmicas, como é o caso do Modelo de Koyck. Abaixo segue a saída do R com o modelo estimado inicialmente. Observa-se que este modelo ainda não passou pelos testes elaborados a seguir, porém se trata da primeira estimativa com as variáveis escolhidas e a partir do banco de dados montado.

```
Time series regression with "ts" data:
```

```
Start = 2005, End = 2019
```

```
Call:
```

```
dynlm(formula = Prod ~ Preco + Cambio + Cons + Estoque.Inicial +  
      Exp + Imp + L(Prod, 1), data = milho.ts)
```

```
Residuals:
```

	Min	1Q	Median	3Q	Max
	-2632.0	-931.2	-315.8	1215.2	2915.9

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-6.446e+04	1.874e+04	-3.439	0.01085	*
Preco	-5.823e+02	2.679e+02	-2.174	0.06624	.
Cambio	1.059e+04	2.975e+03	3.561	0.00921	**
Cons	2.534e+00	5.266e-01	4.811	0.00194	**
Estoque.Inicial	-2.130e+00	4.403e-01	-4.838	0.00188	**
Exp	3.105e-01	2.623e-01	1.184	0.27508	
Imp	-1.867e+00	1.663e+00	-1.123	0.29859	
L(Prod, 1)	9.209e-02	9.356e-02	0.984	0.35780	

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 2386 on 7 degrees of freedom
```

```
Multiple R-squared:  0.9926,    Adjusted R-squared:  0.9852
```

```
F-statistic: 133.7 on 7 and 7 DF,  p-value: 6.464e-07
```

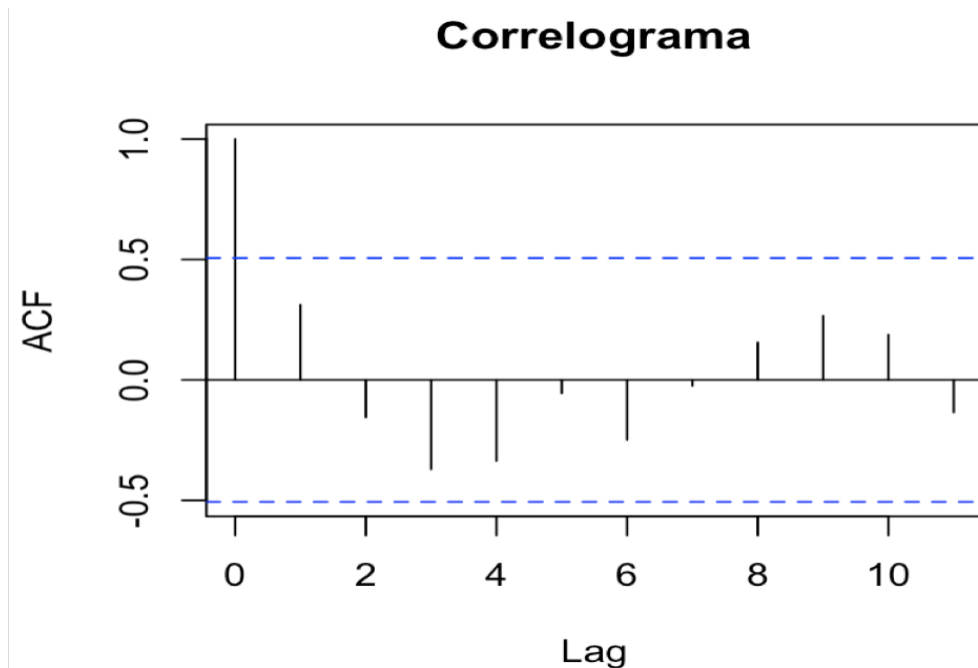
Antes de fazermos afirmações estatísticas, precisamos testar o modelo para heterocedasticidade e também para autocorrelação; e em sequência, se necessário, corrigi-lo para eliminar as possíveis distorções. Como o Modelo de Koyck também utiliza os estimadores MQO para obter resultados não viesados, é imprescindível que esses requisitos sejam atendidos, caso contrário não há confiabilidade no modelo. Para testarmos o quesito da Heterocedasticidade, utilizamos o teste de Breusch-Pagan, cuja Hipótese Nula é a de que o modelo é homocedástico (pré-requisito para validar os modelos que utilizam o método dos Mínimos Quadrados Ordinários); e cuja Hipótese Alternativa é a presença de Heterocedasticidade. No R, há uma função inclusa no pacote “lmtest” que faz o cálculo da estatística de teste de Breusch-Pagan e seu p-valor associado:

```
> bptest(milho.inf)

studentized Breusch-Pagan test

data: milho.inf
BP = 9.1876, df = 7, p-value = 0.2395
```

Com o p-valor associado a estatística BP a chance de cometer um Erro do Tipo I ao rejeitar a H_0 é de 23,95%, maior que até mesmo um nível de significância (alpha) de 10%, portanto podemos afirmar com segurança que o modelo é homocedástico. O próximo teste a ser feito é o da Autocorrelação, e este foi elaborado a partir de análise gráfica e estatística, a última se deu por meio do Teste de Breusch-Godfrey, cuja H_0 é da ausência de Autocorrelação no modelo. Segue abaixo a análise gráfica:



No correlograma, não temos evidências para apoiar a hipótese de que há autocorrelação, entretanto embora o correlograma possa ajudar na identificação da autocorrelação, um teste mais criterioso deve ser aplicado para entender se a autocorrelação é um problema. Esse método é o teste do multiplicador lagrangiano, ou ainda, Teste de Breusch-Godfrey. Há também no pacote “lmtest” uma função que visa fazer este teste, cujos resultados estão apresentados a seguir:

```
> bg_1 <- bgtest(milho.inf, order=1, type="Chisq")  
> bg_1
```

Breusch-Godfrey test for serial correlation of order up to 1

data: milho.inf

LM test = 3.6629, df = 1, p-value = 0.05564

O resultado do teste de Breusch-Godfrey nos indica que a chance de cometermos um Erro do Tipo I ao rejeitarmos a H_0 de que não há autocorrelação é muito baixa, estando muito próxima de um limite de 5% na ordem 1, com um p-valor associado de 5,56%, que já é baixo e alarmante o suficiente para que seja feita uma correção no modelo. Ainda assim, foi repetido o teste, mas desta vez considerando uma ordem de até 4:

```
> bg_4 <- bgtest(milho.inf, order=4, type="Chisq")
> bg_4
```

Breusch-Godfrey test for serial correlation of order up to 4

```
data: milho.inf
LM test = 12.563, df = 4, p-value = 0.01362
```

O p-valor associado ao teste do multiplicador lagrangiano para ordem até 4 é de 1,36%, e confirma as suspeitas anteriores de que há autocorrelação, ou correlação serial, no modelo. Desta forma se faz necessário uma correção no modelo para que este não esteja viesado. MQO não são os melhores estimadores não viesados se a característica de autocorrelação dos erros estiver presente. A autocorrelação não traz viés aos betas, porém prejudica a parte da menor variância, ou seja, o teste-t não é confiável. E se o teste t não é confiável, não se pode afirmar se as variáveis são dependentes.

Para que o modelo seja estimado de forma consistente e corrigida tanto para Heterocedasticidade quanto para Autocorrelação, foi utilizado o método da Correção de Newey-West. No software R, com o auxílio de um pacote chamado “sandwich”, foi utilizado um método de correção cuja matriz de variância-covariância foi corrigida e estimada através de Newey-West, de forma a retirar as distorções do modelo e tornar as estatísticas t do modelo confiáveis. A correção não traz todas as informações do modelo, uma vez que muitas delas não foram distorcidas e mantém seu valor, uma análise individual será realizada logo que o modelo com os testes-t corrigidos seja apresentado, a seguir:

```
> nw_milho.inf <- coeftest(milho.inf, vcov. = NeweyWest(milho.inf))
> nw_milho.inf # Modelo corrigido
```

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-6.4461e+04	8.9296e+03	-7.2188	0.0001746	***
Preco	-5.8229e+02	1.3661e+02	-4.2626	0.0037348	**
Cambio	1.0594e+04	1.4315e+03	7.4004	0.0001494	***
Cons	2.5339e+00	2.5926e-01	9.7736	2.488e-05	***
Estoque.Inicial	-2.1302e+00	1.7696e-01	-12.0379	6.225e-06	***
Exp	3.1053e-01	1.1971e-01	2.5941	0.0357300	*
Imp	-1.8667e+00	4.9748e-01	-3.7524	0.0071460	**
L(Prod, 1)	9.2086e-02	4.0670e-02	2.2642	0.0579708	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Segue abaixo o modelo completo, corrigido pelo método de Newey-West, consistente com Heterocedasticidade e Autocorrelação:

```
Time series regression with "ts" data:
Start = 2005, End = 2019

Call:
dynlm(formula = Prod ~ Preco + Cambio + Cons + Estoque.Inicial +
      Exp + Imp + L(Prod, 1), data = milho.ts)

Residuals:
      Min       1Q   Median       3Q      Max
-2632.0  -931.2  -315.8   1215.2   2915.9

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.4461e+04  8.9296e+03  -7.2188 0.0001746 ***
Preco        -5.8229e+02  1.3661e+02  -4.2626 0.0037348 **
Cambio        1.0594e+04  1.4315e+03   7.4004 0.0001494 ***
Cons          2.5339e+00  2.5926e-01   9.7736 2.488e-05 ***
Estoque.Inicial -2.1302e+00  1.7696e-01 -12.0379 6.225e-06 ***
Exp           3.1053e-01  1.1971e-01   2.5941 0.0357300 *
Imp          -1.8667e+00  4.9748e-01  -3.7524 0.0071460 **
L(Prod, 1)      9.2086e-02  4.0670e-02   2.2642 0.0579708 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2386 on 7 degrees of freedom
Multiple R-squared:  0.9926,    Adjusted R-squared:  0.9852
F-statistic: 133.7 on 7 and 7 DF,  p-value: 6.464e-07
```

O teste t se trata de um teste de hipótese, onde a hipótese nula (H_0) é de que os coeficientes (betas) sejam iguais a zero, seja ele o intercepto (α) ou o coeficiente angular (β_x), mesmo que o usual seja a aplicação do teste-t apenas no coeficiente angular. O objetivo é de que ao verificar a $H_0: \beta_2 = 0$, estamos na verdade verificando se a variável X, atrelada a um β_x , exerce mesmo alguma influencia na variável Y, uma vez que o coeficiente angular é responsável pela inclinação da reta que forma o modelo, se esse valor fosse 0 não haveria relação pois a reta seria horizontal. O valor-p associado se trata da probabilidade de cometer

um erro do Tipo I ao rejeitar H_0 , temos que se esse valor for menor que nosso α nós rejeitaremos H_0 . No modelo temos valores-t altos acima do t-crítico (ponto no qual se cruza o alpha e se ganha significância estatística, com probabilidades associadas aos betas de 1-6 sendo, respectivamente: 0,0037348; 0,0001494; 2,488e-05; 6,225e-06; 0,03573 e 0,0071460, ou seja, podemos estimar que a confiabilidade da nossa estimativa de β_x seja alta e que nosso β_x é diferente de zero.

Com base nos testes-t, concluímos então que todas as variáveis computadas são estatisticamente significantes para explicar a produção de milho, e também que as variáveis Câmbio e Preço são, em ordem de magnitude, as que exercem maior influência sobre a produção. O teste F apresentou um resultado satisfatório, com uma probabilidade associada a estatística F muito pequena, de 6,464e-07, o que significa que ao menos um dos betas exerce influência sobre a variável dependente (y; produção). Quanto a estatística R^2 , é o percentual das nossas observações que pode ser explicado pelo nosso modelo. Ou seja, mede a eficácia do modelo ao prever as observações. R^2 é dado pela formula: $\frac{SquaredSumRegression}{SquaredSumTotals}$. Sabemos que SST corresponde a SSR + SSE, ou seja, temos que R^2 mede a participação da soma dos quadrados da regressão dentro da soma dos quadrados totais. Um valor maior de R^2 significa que a regressão explica mais das observações e um valor menor significa que ha uma participação maior de erros do que de acertos. O \bar{R}^2 (r-squared-adjusted) mede a mesma relação, porem visa prevenir que variáveis menos significantes impactem no resultado de R^2 , onde esta penaliza pelo acréscimo de variáveis não-significantes. No modelo estudado temos um R^2 de 0.9926 e um \bar{R}^2 de 0.9852, que são valores altíssimos, quase a integralidade das observações podem ser explicadas pelo modelo de regressão gerado, o que indica que há maior confiabilidade do que o esperado de uma previsão estimativa, usando essa reta de regressão.

Efeitos esperados de Curto-Prazo (Efeitos Instantâneos)

Seguindo com a apresentação do modelo, temos na tabela abaixo os efeitos esperados instantâneos (curto-prazo) médios, de uma variação em cada uma das variáveis independentes sobre a produção gerada de milho no Brasil. Lembrando que as variações estão em unidades absolutas, e podem sofrer transformações de acordo com o desejado para que sejam obtidos os efeitos em diferentes termos e unidades. Todos os dados tratados nos modelos estão padronizados, sendo que as unidades de peso representam 1 x mil toneladas; e as variáveis monetárias estão em Reais.

	Preço	Câmbio	Consumo Interno	Estoque Inicial	Exportações	Importações
Variação	+ R\$1	+ R\$1	+1.000 ton	+1.000 ton	+1.000 ton	+1.000 ton
Efeito sobre a Produção	-582.290 ton	+1.059.400 ton	+ 2533,9 ton	- 2.130,2 ton	+ 310,5 ton	- 1.866,7 ton

Como o preço e o câmbio são variáveis nas quais a variação de uma unidade representa uma mudança consideravelmente alta, é lógico que façamos a equivalência para o efeito da variação de menos de R\$ 1 em ambas as variáveis. A tabela abaixo mostra o efeito de curto-prazo na produção, proveniente da variação de R\$ 0,10 e de R\$ 0,01 das duas variáveis monetárias:

	Preço		Câmbio	
Variação	+ R\$ 0,10	+ R\$ 0,01	+ R\$ 0,10	+ R\$ 0,01
Efeito sobre a Produção	- 58.229 ton	- 5.822,9 ton	+ 105.940 ton	+ 10.594 ton

Todos os valores quanto aos efeitos, retratam a variação que se espera da produção, em média, dada uma primeira variação de magnitude especificada nas variáveis independentes do modelo. Ou seja, falando do efeito de um aumento no preço do milho em R\$ 1, por exemplo, espera-se que a produção seguinte sofra uma variação negativa absoluta de, em média, -582.290 toneladas. Ou ainda que, com o aumento de R\$ 0,01 no Câmbio, espera-se que a produção

aumente, em média, 10.594 toneladas. Estamos trabalhando com variações positivas nas variáveis independentes, porém os resultados são os modularmente os mesmos, basta fazer a troca de ambos os sinais, da variação e do efeito. Vale notar que os efeitos são efeitos isolados e não consideram a interação entre as variáveis independentes, que também exercem seu próprio efeito na produção, ou seja, são cumulativos.

Efeitos com defasagens nas variáveis independentes

Foram estimados também os efeitos esperados de períodos anteriores (t-x) sobre a produção atual. Uma das vantagens do modelo de Koyck é a possibilidade de estimarmos efeitos defasados sobre todas as variáveis independentes, em qualquer período anterior do intervalo. No modelo de defasagens infinitas, esses efeitos das defasagens nas variáveis independentes, para determinado β_x associado aquela variável, podem ser estimados através da seguinte equação:

$$\beta_x * (\lambda^{tx})$$

Onde: tx = período anterior t-x, em valor absoluto. Exemplo para 2 defasagens: λ^2

As duas variáveis mais relevantes (dada a magnitude de sua influência sobre produção) foram testados os seus efeitos com até três defasagens, essas variáveis são: Câmbio e Preço. Segue abaixo uma tabela que apresenta os resultados nos períodos t-1; t-2 e t-3, ou seja, qual o efeito de uma variação que tenha ocorrido nessas variáveis, de magnitude especificada, que tenha ocorrido há 1; 2 e 3 anos, respectivamente, e o efeito corresponde a influência que essa variação destes períodos passados ainda está exercendo hoje sobre a produção:

	Preço		
Variação	+ R\$1		
Período	t-1	t-2	t-3
Efeito sobre a Produção	- 53.620,3 ton	- 4.937,65 ton	- 454,69 ton

	Câmbio		
Variação	+ R\$0,10		
Período	t-1	t-2	t-3
Efeito sobre a Produção	- 97.554,4 ton	- 8.983,35 ton	- 827,24 ton

Abaixo temos os valores referentes aos efeitos das demais variáveis independentes defasadas em t-1:

	Consumo Interno	Estoque Inicial	Exportações	Importações
Variação	+1.000 ton	+1.000 ton	+1.000 ton	+1.000 ton
Período	t-1			
Efeito sobre a Produção	+ 233,33 ton	- 196,16 ton	+ 28,60 ton	- 171,8995 ton

Efeitos de Longo Prazo

Os efeitos de Longo Prazo são os efeitos totais esperados de uma variação de dada magnitude nas variáveis independentes (explicativas), sobre a produção, mas considerando todos os períodos futuros t+1, t+2, t+3, assim por diante. No modelo de Koyck, os efeitos de Longo Prazo para determinado β_x podem ser estimados através da seguinte equação:

$$LP = \beta_x * \left(\frac{1}{(1 - \lambda)} \right)$$

Ou seja, trata-se do efeito que esperamos uma variável independente ter sobre a produção em todo o período futuro em que ela estiver exercendo alguma influência. Com essa

estimativa, conseguimos saber o efeito total ao longo do tempo de determinada variação nas variáveis explicativas, e abaixo seguem os resultados observados:

	Preço	Câmbio	Consumo Interno	Estoque Inicial	Exportações	Importações
Variação	+ R\$1	+ R\$0,10	+1.000 ton	+1.000 ton	+1.000 ton	+1.000 ton
Efeito de LP sobre a Produção	- 641.346 ton	+1.166.837 ton	+ 2.790,88 ton	- 2.346,24 ton	+ 342,03 ton	- 2.056,07 ton

Defasagem Mediana e Média

A Defasagem Mediana é uma estatística que busca estabelecer o tempo que se leva para que ocorra a metade (50%) do Efeito de Longo Prazo total. Com base nesse dado, podemos nos situar quanto a velocidade de reação da produção para modificações em alguma das variáveis independentes. O cálculo da defasagem mediana para o Modelo de Koyck pode ser estimado usando a seguinte equação, e abaixo dela segue o resultado dessa estatística para o nosso modelo.

$$Def. Mediana = \frac{-\log(2)}{\log(\lambda)}$$

$$Def. Mediana Prod. Milho = 0,2906263 \text{ anos} \approx 3 \text{ meses e } 15 \text{ dias}$$

Já no caso da Defasagem Média, é uma estatística que busca estimar o tempo que se leva para perceber o efeito de uma variação em alguma das variáveis independentes na variação da produção do milho. Abaixo temos a equação utilizada para estimar a defasagem média em um Modelo de Koyck de defasagens ilimitadas, e segue também o resultado dessa estatística para o nosso modelo sobre a produção de milho:

$$Def. Média = \frac{\lambda}{(1 - \lambda)}$$

$$Def. Média Prod. Milho = 0,1014254 \text{ anos} \approx 1 \text{ mês e } 7 \text{ dias}$$

O que essas estatísticas nos mostram quando interpretadas, é que os efeitos na produção de variações nas variáveis explicativas do modelo se dá de forma rápida, já sendo percebido em

pouco mais de 1 mês, e tendo metade do seu efeito de Longo Prazo se dando em apenas 3 meses e 15 dias aproximadamente. Portanto sabemos com embasamento no nosso diagnóstico até então, que há efeitos de defasagens passadas em jogo no presente, e ainda que dada a magnitude da influencia de algumas variáveis como o Câmbio, principalmente, e também o Preço, sabemos que a maior parte do efeito se dá no período atual, no mesmo ano em que ocorre a variação, então trata-se de um mercado volátil e de rápida reação a intempéries.

Previsões de Cenários (Otimista; Conservador e Pessimista)

Para que fizéssemos as previsões munidos das influências das variáveis explicativas de nosso modelo, fizemos o cálculo de um \hat{y} baseado em estimativas de X para as variáveis independentes, que por sua vez se deu por meio de a elaboração de um modelo autoregressivo para cada uma das variáveis independentes.

$$Prod = \alpha + \beta_{preco}\hat{X}_{preco} + \beta_{cambio}\hat{X}_{cambio} + \beta_{cons}\hat{X}_{cons} + \beta_{est.inic}\hat{X}_{est.inic} + \beta_{exp}\hat{X}_{exp} + \beta_{imp}\hat{X}_{imp}$$

Em um modelo autoregressivo, a variável explica ela mesma, com base na sua série temporal. Utilizamos todos os dados disponíveis sobre cada uma das variáveis para fazermos esses modelos autoregressivos a parte, e abaixo segue o intervalo utilizado para cada uma delas:

Preço	2004 - 2019
Estoques iniciais; Consumo Interno; Importações; Exportações	2000 - 2019

Calculando os modelos autoregressivos, e posteriormente por meio de um pacote no R chamado “forecast”, utilizamos sua função para estimarmos intervalos de confiança de 95%

para o valor em 2020 de cada uma das variáveis explicativas do Modelo de Koyck. Consideramos então o limite inferior do intervalo de confiança (Lo95) como sendo um cenário pessimista para esta variável, o limite superior do intervalo de confiança (Hi95) como sendo um cenário otimista para essa mesma variável. No caso do cenário conservador foi utilizada a mediana entre os valores Lo95 e Hi95. Seguem abaixo as previsões para as variáveis explicativas para serem usados como X do \hat{y} :

```
> fc.preco
      Point.Forecast  Lo.80   Hi.80   Lo.95   Hi.95
2020      45.02691 42.1726 47.88122 40.66162 49.3922
> fc.cons
      Point.Forecast  Lo.80   Hi.80   Lo.95 Hi.95
2020      65057.65 64189.08 65926.21 63729.29 66386
> fc.est
      Point.Forecast  Lo.80   Hi.80   Lo.95   Hi.95
2020      26255.37 24550.96 27959.79 23648.7 28862.05
> fc.exp
      Point.Forecast  Lo.80   Hi.80   Lo.95   Hi.95
2020      123525.1 120644 126406.2 119118.8 127931.3
> fc.imp
      Point.Forecast  Lo.80   Hi.80   Lo.95   Hi.95
2020      14472.1 14203.91 14740.28 14061.94 14882.25
```

Segue abaixo os dados processados em cenários pessimista, conservador e otimista. A única variável que não foi capaz estimar foi o câmbio, portanto foi utilizada a média de 2019 como X para o $\beta_{(cambio)}$.

Previsões para 2020	Cenários	Preço	Consumo Interno	Estoque Inicial	Exportações	Importações
	Pessimista	R\$ 49,39	63729,29	23648,70	119118,80	14882,25
	Conservador	R\$ 45,03	65057,65	26255,38	123525,05	14472,10
	Otimista	R\$ 40,66	66386,00	28862,05	127931,30	14061,94

Com os dados desenvolvidos na análise acima, fizemos as previsões do \hat{y} para 2020 inserindo na equação da reta da regressão os valores dos Betas encontrados e bem como do X esperado para cada variável independente em cada um dos cenários calculados acima. Com isso, temos um \hat{y} para cada cenário como forma de previsão da quantidade absoluta produzida esperada, em média, em 2020.

		Previsão Produção Milho
Previsões para 2020	Pessimista	68.305.720 toneladas
	Conservador	70.791.610 toneladas
	Otimista	73.282.350 toneladas